Serve Lab

Mejora del saque de tenis con IA frente a un entrenador personal · Propuesta de proyecto · CC3092 Proyecto Final · Ernesto y Hugo · 26 de octubre de 2026

1. Propuesta

Serve Lab analiza el saque de tenis a partir de un video corto grabado con el teléfono y le dice al jugador qué corregir y con qué ejercicio. Es la evolución del asistente del Proyecto 3, que usa solo un modelo de visión y lenguaje (Qwen3-VL-4B). En el Proyecto Final le agregamos MediaPipe Pose Landmarker, la biblioteca gratuita y de código abierto de Google (Apache-2.0) que ubica 33 puntos del cuerpo, en coordenadas, en cada cuadro del video. MediaPipe corre en la misma computadora, sin internet, sin clave de API y sin costo por video; en nuestras pruebas con 7 saques procesó unos 165 cuadros por segundo en una Mac M5, contra 113 de YOLO Pose, con 44 % menos temblor entre cuadros. Lo usamos sin reentrenar, como extractor de características, para ubicar el cuadro exacto de cada fase del saque, recortar al jugador, medir ángulos contra rangos publicados y limitar la respuesta del modelo a lo que la evidencia respalda. Sobre esas entradas ajustamos Qwen3-VL con LoRA usando nuestros saques etiquetados. La métrica de negocio es **cuánto mejora el saque de una persona, en porcentaje, desde que empieza a usar Serve Lab, comparado con una persona que no lo usa y entrena con un entrenador personal en persona** durante el mismo periodo. Ambos grupos hacen la misma prueba al inicio y al final, y la mejora se calcula como (resultado final − resultado inicial) / resultado inicial. Además comparamos tres versiones del modelo: A, el sistema del Proyecto 3 sin pose; B, con pose y prompt; y C, con pose y LoRA. Las comparamos en métricas técnicas (F1 por categoría de error, tasa de alucinación y latencia) y en la mejora que se espera que produzca cada una.

2. Justificación

Un entrenador personal es la forma habitual de mejorar el saque, pero cobra por hora y no está presente cada vez que el jugador practica solo. La pregunta de negocio es qué parte de la mejora que logra un entrenador consigue Serve Lab, y a qué costo: si el grupo con Serve Lab mejora *x* % y el grupo con entrenador mejora *y* %, el cociente *x*/*y* indica cuánto del efecto de las clases reemplaza la app, y el costo por punto de mejora (costo del periodo / mejora) indica si conviene. El precio de la clase lo cotizaremos con academias de la ciudad; el costo de Serve Lab es casi cero porque todo corre en la computadora del jugador. Esa mejora depende de la calidad del modelo: una recomendación correcta lleva la práctica al error real, y una alucinación hace practicar el ejercicio equivocado. Ya lo vimos con los primeros 7 videos: el modelo dijo en todos que el brazo de lanzamiento baja antes de tiempo, aunque la pose muestra que en 2 de ellos sigue arriba hasta el impacto. Por eso relacionamos la métrica técnica con la de negocio: durante el estudio registramos qué recomendaciones fueron correctas según las etiquetas acordadas, estimamos cuánto mejora un jugador por cada recomendación correcta y usamos esa relación para traducir el F1 y la tasa de alucinación de las versiones A, B y C en mejora esperada y costo por punto. Usamos deep learning porque las reglas fijas sobre ángulos no alcanzan con una sola cámara: varios errores solo se ven en

los cuadros. Los supuestos (precio de la clase, sesiones por semana y relación entre aciertos y mejora) pasan por un análisis de sensibilidad de ±20 % y ±50 %.

3. Fuente de datos

- **Estudio de mejora (datos nuevos):** dos grupos de 3 a 5 jugadores amateurs de nivel parecido. El grupo Serve Lab practica solo con la app; el grupo de control no usa la app y ya toma clases con un entrenador personal en persona. Los dos practican del 3 al 13 de noviembre con el mismo número de sesiones, y cada sesión queda registrada (fecha, duración y saques practicados).
- **Prueba inicial y final, igual para todos:** 20 saques grabados de lado según `docs/grabacion.md`. Medimos dos resultados: el porcentaje de saques que entran en el cuadro de saque, que anota en la cancha un integrante del grupo, y un puntaje técnico, el porcentaje de fases sin error visible, que Ernesto y Hugo califican con los videos mezclados, sin saber de qué grupo ni de qué prueba son.
- **Saques etiquetados para ajustar y evaluar el modelo:** de 40 a 60 saques tomados de las pruebas y de la práctica, más 4 a 6 videos inválidos a propósito. Ernesto y Hugo etiquetan por separado el error principal de cada saque (validez, fase, categoría de error y ejercicio); reportamos su acuerdo con el kappa de Cohen y resolvemos juntos los desacuerdos. Aquí "entrenar" se refiere al modelo, no al jugador: los saques se dividen por jugador en entrenamiento, validación y prueba. Con los de entrenamiento el modelo aprende (LoRA), la validación indica cuándo detener el ajuste y la prueba es el examen final, que el modelo nunca ve. Las etiquetas se escriben una sola vez: el objetivo no es acertar en esos saques, que ya tienen respuesta, sino diagnosticar los saques nuevos de jugadores que nadie etiquetó.
- **Datos derivados:** secuencias de 33 puntos por cuadro generadas con MediaPipe, cuadros clave y ángulos de cada saque.
- **Criterios de referencia:** estudios publicados de biomecánica del saque (Kovacs y Ellenbecker, 2011; Jacquier-Bret y Gorce, 2024).
- **Privacidad y límites:** todos los jugadores firman su consentimiento, los videos no se suben al repositorio y se procesan localmente. Los grupos no son aleatorios, el periodo es corto y los calificadores no son expertos; lo reportamos como limitación.

Referencias

- Kovacs, M. y Ellenbecker, T. (2011). An 8-stage model for evaluating the tennis serve. *Sports Health*, 3(6), 504-513. doi:10.1177/1941738111414175
- Jacquier-Bret, J. y Gorce, P. (2024). Kinematics characteristics of key point of interest during tennis serve among tennis players: a systematic review and meta-analysis. *Frontiers in Sports and Active Living*. doi:10.3389/fspor.2024.1432030
- MediaPipe Pose Landmarker: github.com/google-ai-edge/mediapipe · Qwen3-VL-4B-Instruct: huggingface.co/Qwen/Qwen3-VL-4B-Instruct · MLX-VLM: github.com/Blaizzy/mlx-vlm